

DOCUMENTATION TECHNIQUE

Pipeline de Préparation et de Prédiction des Décès COVID-19

Dataiku DSS — Machine Learning Pipeline

Plateforme	Dataiku Data Science Studio (DSS)
Type de Projet	Pipeline de Machine Learning — Régression
Objectif	Prédire le nombre de décès liés au COVID-19
Dataset Principal	02_05_2021 (données COVID-19)
Dataset Secondaire	Continent_Country_Mapping
Modèle	Régression (Predict Deaths)
Variable Cible	Deaths (nombre de décès)

1. Description du Projet

Ce projet a pour objectif de construire un pipeline complet de Machine Learning au sein de la plateforme Dataiku DSS, appliqué à l'analyse des données de la pandémie COVID-19. Il illustre un flux de traitement de données (Flow) allant de l'importation brute des données jusqu'à l'évaluation d'un modèle prédictif de régression.

Le pipeline prend en entrée deux jeux de données : les statistiques COVID-19 mondiales (cas confirmés, décès, guérisons par pays et par date) et une table de correspondance pays-continent. Ces données sont ensuite fusionnées, nettoyées, transformées, filtrées, puis utilisées pour entraîner un modèle de régression dont la variable cible est le nombre de décès. Le modèle final est évalué et ses prédictions sont exportées dans un dataset scoré.

Valeur Métier du Projet

Ce pipeline permet aux data scientists et équipes de santé publique de comprendre les facteurs influençant la mortalité COVID-19, d'anticiper les décès selon les caractéristiques épidémiologiques d'une région, et d'évaluer objectivement la performance prédictive du modèle grâce à des métriques standardisées.

1.1 Architecture Générale du Flow

Le Flow Dataiku DSS est organisé en huit étapes séquentielles, chacune représentée par un nœud dans le graphe de traitement :

- Importation des datasets bruts
- Jointure (Join) des datasets par pays
- Préparation et nettoyage des données
- Filtrage des données (focus sur les États-Unis)
- Division Train / Test
- Entraînement du modèle de régression
- Déploiement et scoring du modèle sur les données de test
- Évaluation des performances du modèle

2. Étapes Détaillées du Pipeline

Étape 1



Importation des Données

Chargement des datasets sources dans Dataiku DSS

Description

La première étape consiste à importer les deux jeux de données nécessaires au projet directement dans l'environnement Dataiku DSS. Ces datasets constituent la matière première du pipeline et sont chargés en tant que datasets managés dans le projet.

Datasets Importés

- **02_05_2021** : Dataset principal contenant les données épidémiologiques COVID-19 au niveau mondial. Il comprend des informations par pays et par date, notamment le nombre de cas confirmés, de décès et de guérisons. La date de référence du dataset est le 2 mai 2021.
- **Continent_Country_Mapping** : Table de référence permettant d'associer chaque pays à son continent. Ce dataset enrichit les données COVID en ajoutant une dimension géographique de niveau supérieur.

Configuration dans Dataiku

Dans Dataiku DSS, l'import se fait via le menu « + Dataset » dans le Flow. Les fichiers peuvent être chargés depuis le système de fichiers local, un stockage cloud (S3, GCS, Azure Blob) ou une connexion base de données. Chaque dataset importé apparaît comme un nœud de couleur verte dans le Flow.

Étape 2



Jointure des Datasets

Fusion des deux datasets sur la colonne pays pour créer Joined_covid_Data

Description

Une fois les deux datasets disponibles, une opération de jointure (Join) est effectuée pour fusionner les données épidémiologiques avec la table de correspondance pays-continent. La recette Join de Dataiku génère un nouveau dataset enrichi : Joined_covid_Data.

Paramètres de la Jointure

- Type de jointure : LEFT JOIN — garantit la conservation de l'intégralité des données COVID même si certains pays n'ont pas de correspondance dans la table de mapping.
- Clé de jointure : Colonne Country (pays) présente dans les deux datasets.
- Dataset résultant : Joined_covid_Data, qui contient toutes les colonnes des deux sources fusionnées.

Pourquoi un LEFT JOIN ?

Le choix du LEFT JOIN est stratégique : il préserve toutes les lignes du dataset COVID principal (gauche), même si un pays n'est pas référencé dans la table de mapping des continents. Cela évite toute perte de données épidémiologiques et garantit l'intégrité du dataset résultant.

Étape 3**Préparation des Données**

Nettoyage et transformation dans Joined_covid_Data_prepared

Description

La préparation des données est une étape cruciale du pipeline. Elle vise à transformer le dataset brut issu de la jointure en un dataset propre, cohérent et prêt pour la modélisation. Cette étape est réalisée via la recette Prepare de Dataiku DSS, qui offre une interface graphique pour appliquer des transformations sans code.

Opérations Réalisées

- Nettoyage des valeurs manquantes (NaN) : remplacement ou suppression des cellules vides dans les colonnes critiques.
- Conversion des types de données : vérification et correction des types (entiers, flottants, chaînes de caractères, dates).
- Transformation des variables : création ou modification de colonnes pour améliorer la qualité des features.
- Suppression des colonnes redondantes ou non pertinentes pour la prédiction.
- Normalisation des noms de colonnes pour assurer la cohérence du schéma.

Dataset Produit

Joined_covid_Data_prepared — Dataset nettoyé et transformé, prêt pour la division et la modélisation. Ce dataset constitue la base de toutes les étapes suivantes du pipeline.

Étape 4**Filtrage des Données**

Filtrage par pays : focus sur les États-Unis (US)

Description

Une étape de filtrage est appliquée pour restreindre l'analyse à un pays spécifique. Dans ce pipeline, les données sont filtrées pour ne conserver que les enregistrements correspondant aux États-Unis (US). Ce filtrage permet de construire un modèle plus précis et homogène sur une zone géographique définie.

Paramètres du Filtre

- Condition : Country == 'US' (colonne pays égale à 'US').
- Type de recette : Filter dans Dataiku DSS, appliquée sur Joined_covid_Data_prepared.

- Résultat : Dataset filtré ne contenant que les données américaines.

Justification Métier

Se concentrer sur les États-Unis permet d'éliminer la variance géographique et socio-économique inter-pays, rendant le modèle de régression plus performant sur un contexte homogène. Cela correspond aussi à un cas d'usage réel : construire un outil prédictif spécifique à un pays.

Étape 5

**Division Train / Test**

Séparation du dataset en jeux d'entraînement et de test

Description

Le dataset filtré est ensuite divisé en deux sous-ensembles distincts : le jeu d'entraînement (Train_Dataset) et le jeu de test (Test). Cette séparation est fondamentale en Machine Learning pour évaluer les performances d'un modèle sur des données qu'il n'a jamais vues lors de l'entraînement.

Paramètres de Division

- Recette utilisée : Split dans Dataiku DSS.
- Train_Dataset : Portion des données utilisée pour entraîner le modèle (typiquement 70 à 80% des données).
- Test : Portion réservée pour l'évaluation finale du modèle (20 à 30% restants).
- Mode de division : Aléatoire ou chronologique selon la nature temporelle des données.

Bonne Pratique

La division Train/Test garantit que les métriques d'évaluation reflètent la capacité de généralisation réelle du modèle. Sans cette séparation, le modèle risque d'être surappris (overfitting) et de donner des performances artificiellement élevées.

Étape 6

**Entraînement du Modèle**

Entraînement du modèle de régression — Variable cible : Deaths

Description

Le modèle de Machine Learning est entraîné sur le Train_Dataset en utilisant le plugin AutoML de Dataiku DSS. La tâche est une régression supervisée dont l'objectif est de prédire le nombre de décès (colonne Deaths) à partir des autres variables du dataset.

Configuration du Modèle

- Type de tâche : Régression (prédiction d'une valeur numérique continue).
- Variable cible (target) : Deaths — nombre de décès COVID-19.
- Features utilisées : Toutes les autres colonnes pertinentes du Train_Dataset (cas confirmés, guérisons, pays, continent, date, etc.).
- Algorithmes évalués : Dataiku DSS teste automatiquement plusieurs algorithmes (Ridge, Random Forest, Gradient Boosting, etc.) et sélectionne le meilleur.

- Métriques d'optimisation : R^2 , RMSE (Root Mean Square Error), MAE (Mean Absolute Error).

Modèle Produit

Predict Deaths (regression) — Modèle entraîné et sauvegardé dans Dataiku DSS, prêt à être déployé pour scorer de nouvelles données.

Étape 7

**Déploiement & Scoring**

Application du modèle sur le dataset Test — Génération de Test_scored

Description

Après l'entraînement, le modèle est déployé et appliqué sur le dataset Test pour générer des prédictions. Cette étape, appelée scoring, utilise la recette Score de Dataiku DSS pour produire le dataset Test_scored contenant les prédictions du modèle pour chaque enregistrement du jeu de test.

Processus de Scoring

- Déploiement : Le modèle entraîné est déployé comme un modèle actif dans Dataiku DSS.
- Recette Score : Applique le modèle sur chaque ligne du dataset Test.
- Dataset généré : Test_scored — contient toutes les colonnes originales du Test plus une colonne prediction avec les valeurs prédites de Deaths.
- Les prédictions peuvent être comparées aux valeurs réelles pour calculer les métriques de performance.

Étape 8

**Évaluation du Modèle**

Analyse des performances via le module d'évaluation Dataiku DSS

Description

La dernière étape du pipeline est l'évaluation rigoureuse des performances du modèle. Dataiku DSS fournit un tableau de bord complet permettant d'analyser plusieurs métriques et visualisations pour juger de la qualité du modèle de régression.

Métriques d'Évaluation

- R^2 (Coefficient de détermination) : Mesure la proportion de la variance expliquée par le modèle. Un R^2 proche de 1 indique un modèle performant.
- RMSE (Root Mean Square Error) : Racine de l'erreur quadratique moyenne. Indique l'écart moyen entre les prédictions et les vraies valeurs.
- MAE (Mean Absolute Error) : Erreur absolue moyenne, moins sensible aux outliers que le RMSE.
- Courbe des résidus : Analyse de la distribution des erreurs pour détecter les biais systématiques.

Dashboard de Performance Dataiku

Dataiku DSS génère automatiquement un rapport de performance incluant : les métriques sur les données de test, les graphiques de prédictions vs valeurs réelles, l'importance des features (feature importance), et la courbe de distribution des erreurs.

3. Architecture du Flow Dataiku DSS

Le diagramme ci-dessous illustre la structure séquentielle du pipeline tel qu'il apparaît dans le Flow de Dataiku DSS. Chaque rectangle représente un dataset (nœud vert) ou une recette (nœud jaune/orange) dans le graphe.

	02_05_2021 + Continent_Country_Mapping	Datasets Sources
	Join Recipe	Jointure par Country
	Joined_covid_Data	Dataset Fusionné
	Prepare Recipe	Nettoyage & Transformation
	Joined_covid_Data_prepared	Dataset Préparé
	Filter Recipe	Filtrage US
	Split Recipe	Division Train / Test
	Train_Dataset + Test	Datasets Train & Test
	Train Recipe (AutoML)	Entraînement Régression
	Score Recipe	Scoring sur Test
	Test_scored	Dataset Final avec Prédictions
	Evaluate Recipe	Évaluation des Performances

4. Inventaire des Datasets

Le pipeline manipule les datasets suivants, dans l'ordre du Flow :

Dataset	Type	Description	Généré Par
02_05_2021	Source	Données COVID-19 mondiales (cas, décès, guérisons)	Import
Continent_Country_Mapping	Source	Table pays → continent	Import
Joined_covid_Data	Intermédiaire	Fusion des deux sources par pays	Join Recipe
Joined_covid_Data_prepared	Intermédiaire	Données nettoyées et transformées	Prepare Recipe
Train_Dataset	Intermédiaire	Données d'entraînement (filtrées US, ~70-80%)	Split Recipe
Test	Intermédiaire	Données de test (~20-30%)	Split Recipe
Test_scored	Final	Données de test + prédictions du modèle	Score Recipe

5. Conclusion et Perspectives

Ce pipeline Dataiku DSS constitue un exemple complet et reproductible d'un projet de Machine Learning appliqué à des données de santé publique. Il couvre l'ensemble du cycle de vie d'un projet data science : de la collecte et préparation des données jusqu'à l'évaluation du modèle déployé.

5.1 Points Forts du Pipeline

- Reproductibilité : Le Flow Dataiku DSS est entièrement traçable et rejouable.
- Modularité : Chaque étape est indépendante et peut être modifiée sans impacter les autres.
- Intégrité des données : Le LEFT JOIN garantit qu'aucune donnée épidémiologique n'est perdue.
- Évaluation rigoureuse : La séparation Train/Test assure une évaluation non biaisée du modèle.

5.2 Pistes d'Amélioration

- Étendre l'analyse à d'autres pays ou continents pour un modèle plus généraliste.
- Intégrer des variables temporelles (séries temporelles) pour capturer les tendances de la pandémie.

- Tester des algorithmes plus avancés (XGBoost, LightGBM, réseaux de neurones).
- Mettre en place un pipeline de réentraînement automatique (retraining) avec de nouvelles données.
- Ajouter une étape de feature engineering pour créer des variables dérivées (taux de mortalité, taux de croissance).

Technologies Utilisées

Dataiku DSS (Flow, Recipes, AutoML, Evaluate) | Python | Machine Learning (Régression supervisée) | Traitement de données tabulaires COVID-19